CENTRO UNIVERSITÁRIO SANTO AGOSTINHO
CURSO: ENGENHARIA DE SOFTWARE
DISCIPLINA: ACE: Análise Inteligente de Dados
PROFESSORA: HELOÍSA GUIMARÃES

EMPRESA EFATÁ – RELATÓRIO DE PROGRESSO

GIOVANE FERREIRA PAES RIBEIRO
JOÃO VITOR RODRIGUES SANTOS
JULIA BEATRIZ BORGES
LIA RACHEL FERREIRA DE SOUSA
PAMELLA ROBERTA DOS SANTOS SILVA

TERESINA - PI

JUNHO/2026

1. Coleta e Preparação de Dados

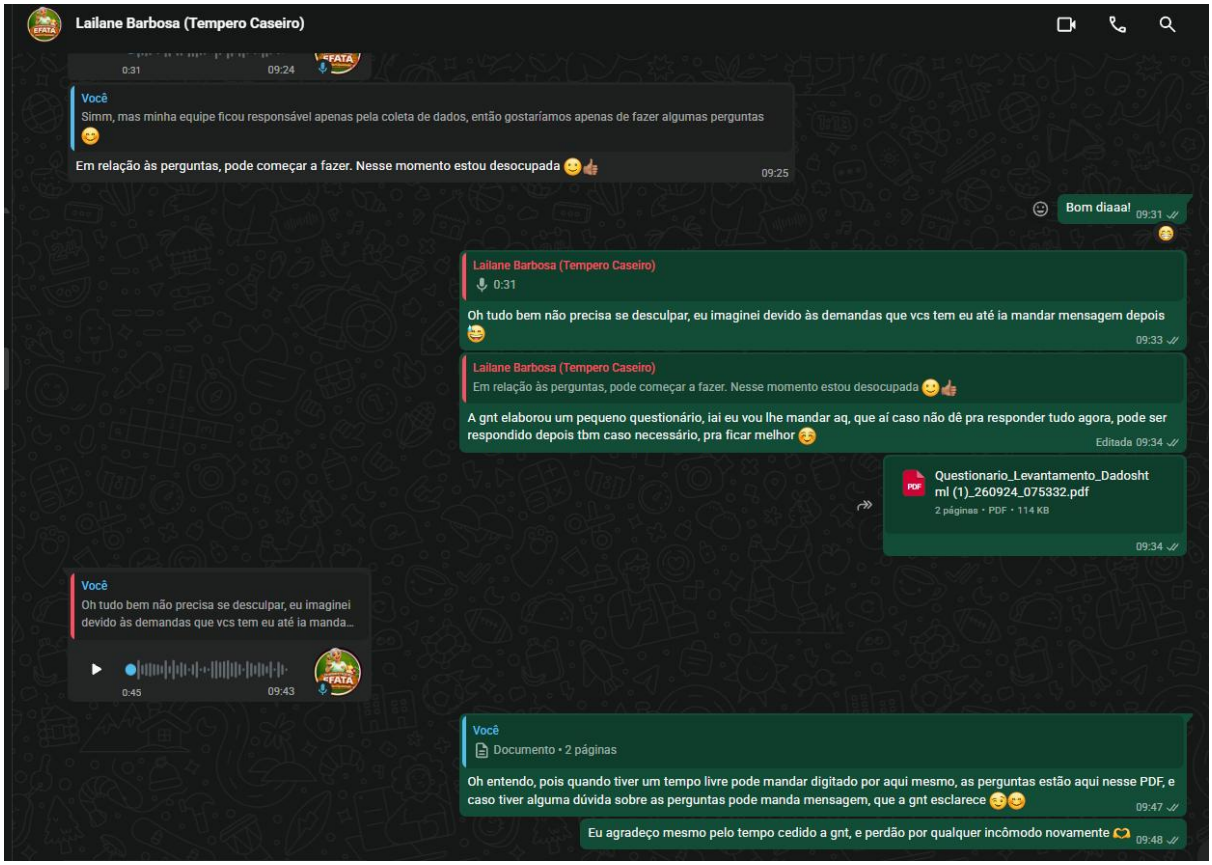
Para montar a base de dados do projeto, conversamos com a proprietária da empresa Efáta por WhatsApp para entender a rotina e como ela fazia os registros. Como um encontro presencial não foi possível, alinhamos o levantamento de forma remota através de um questionário.

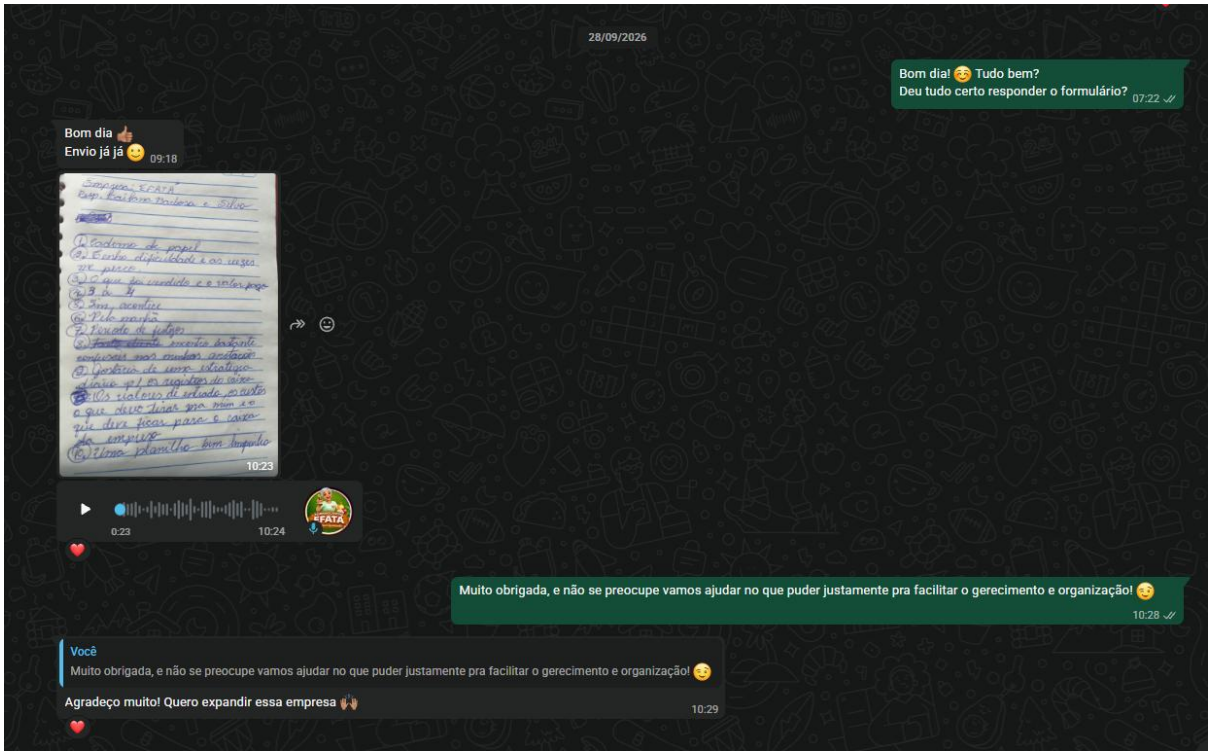
Com base nas respostas, definimos o objetivo de tratar as informações para entregar uma planilha organizada e livre de erros. No entanto, os dados reais fornecidos eram limitados a um período de três dias, totalizando apenas 18 linhas.

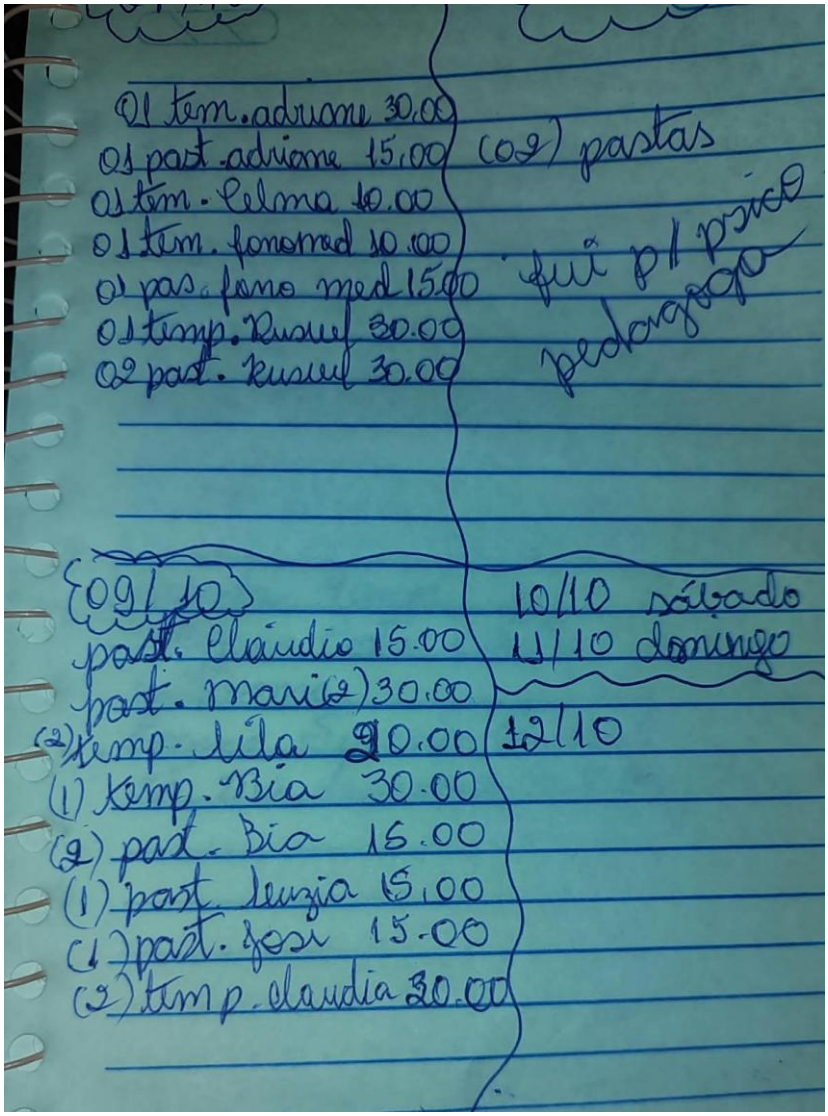
Para viabilizar testes mais completos e o desenvolvimento dos algoritmos de tratamento, utilizamos a plataforma **Mockaroo** para gerar dados sintéticos e realistas. Com essa ferramenta, conseguimos expandir o volume da base e simular propositalmente alguns erros e inconsistências para testar a eficiência da limpeza de dados.

Anexos

- **1.1. Prints das conversas:***(Observação: registro do contato com a proprietária, que informou a impossibilidade de reunião presencial)*




28/09/2026
Bom dia! Tudo bem?
Deu tudo certo responder o formulário? 07:22
Bom dia
Envio já já 09:18
10:23
0:23 10:24
Muito obrigada, e não se preocupe vamos ajudar no que puder justamente pra facilitar o gerecimento e organização! 10:28
Você
Muito obrigada, e não se preocupe vamos ajudar no que puder justamente pra facilitar o gerecimento e organização!
Agradeço muito! Quero expandir essa empresa 10:29


01 tem. adriane 30.00
01 past. adriane 15.00 (02) pastas
01 tem. Celma 30.00
01 tem. fonomed 30.00
01 pas. fono med 15.00 fui p/ psico pedagogo
01 temp. Rusuel 30.00
02 past. Rusuel 30.00
(09/10)
past. Claudio 15.00
past. mari (2) 30.00
(2) temp. Lila 30.00
(1) temp. Bia 30.00
(2) past. Bia 15.00
(1) past. Lenzia 15.00
(1) past. Josi 15.00
(2) temp. claudia 30.00
10/10 sábado
11/10 domingo
12/10

- **1.2. Questionário utilizado na coleta:** *https://canva.link/kt0bqxdo07occjn*

2. Problemas e Soluções (Protótipo do Algoritmo)

2.1. Diagnóstico de Problemas

1. Inconsistências de Formato de Data

- **Formatos variados ou inválidos:** Ausência de um padrão único, com registros utilizando pontos (07.10.2026), traços/hífens, formato curto, formato ISO ou descrições por extenso.
- **Campos de data vazios:** Linhas com o campo de data totalmente em branco.

2. Erros de Escrita e Formatação em Clientes (nome_cliente)

- **Caixa e espaçamentos incorretos:** Nomes cadastrados com letras maiúsculas/minúsculas desalinhadas, uso excessivo de espaços duplos ou formatação inconsistente (ex: fono med vs. fonomed, além de letras minúsculas isoladas).
- **Campos de cliente vazios:** Linhas registradas sem o nome do cliente.

3. Erros em Produtos (produto)

- **Erros de digitação (*typos*):** Erros ortográficos nos nomes dos produtos (ex: tmepero em vez de tempero).
- **Inconsistências de caixa e espaços:** Produtos escritos inteiramente em letras maiúsculas (UPPER) ou contendo espaços extras indesejados.

4. Problemas com Quantidades (quantidade)

- **Texto por extenso:** Quantidades inseridas por extenso (ex: um) em vez de valores numéricos.
- **Tipagem incorreta:** Números armazenados como texto comum.
- **Outliers e valores extremos:** Quantidades desproporcionais ou valores iguais a zero/negativos.
- **Campos vazios:** Linhas sem preenchimento na coluna de quantidade.

5. Problemas com Valores Unitários (valor_unitario)

- **Mistura de moeda e texto:** Valores contendo símbolos monetários (R$), vírgulas no lugar de pontos decimais ou texto explícito.
- **Outliers:** Valores unitários absurdamente altos (ex: 3000 onde o esperado seria menor) ou valores menores/iguais a zero.
- **Campos vazios:** Registros sem o preço unitário preenchido.

6. Duplicidades

- **Duplicatas exatas:** Linhas inteiramente repetidas (cópia exata de outros registros).
- **Duplicatas aproximadas:** Registros duplicados com pequenas variações (ex: nomes de clientes escritos em letras maiúsculas).

2.2. Soluções Implementadas no Código

1. Importação e Inspeção Inicial dos Dados

- **Carregamento:** O arquivo Excel (Empresa_efata.xlsx) foi importado diretamente do Google Drive.
- **Análise Inicial:** Verificação das informações gerais da base de dados bruta — que continha inicialmente **547 linhas e 5 colunas** (data, nome_cliente, produto, quantidade, valor_unitario) —, identificando valores nulos e gerando estatísticas descritivas iniciais.

2. Padronização da Coluna de Datas

- **Limpeza de Formato:** Remoção de espaços em branco e substituição de caracteres separadores incorretos (como pontos ou barras invertidas) por barras padrão (/).
- **Conversão:** A coluna foi convertida para o tipo de data (datetime) utilizando formato misto e tratamento de erros (errors='coerce') para neutralizar registros inválidos ou vazios.

3. Normalização de Textos (nome_cliente e produto)

- **Padronização:** As colunas de texto foram convertidas para strings, tiveram espaços invisíveis removidos, foram convertidas para letras minúsculas (lower()), e múltiplos espaços internos foram reduzidos para apenas um.
- **Impacto:** Redução da dispersão de variações escritas (por exemplo, diminuiu o número de valores únicos de clientes de 486 para 476).

4. Conversão e Limpeza de Campos Numéricos

- **Números por Extenso:** Implementação de lógica para converter números escritos por extenso na coluna de quantidade (como 'um' para 1) em valores numéricos reais.
- **Moedas e Símbolos:** Remoção de símbolos monetários (R$), espaços e ajuste de separadores decimais e de milhar na coluna valor_unitario.
- **Tipagem:** Conversão para tipos numéricos adequados (Int64 para quantidade e float64 para valor unitário).

5. Tratamento de Outliers e Valores Anômalos

- **Filtro de Consistência:** Remoção de registros que continham quantidades ou valores unitários menores ou iguais a zero.
- **Identificação por IQR (Amplitude Interquartil):** O limite superior para os preços unitários foi calculado via método IQR, permitindo identificar e isolar valores absurdos ou extremos (outliers elevados, como preços de R$ 3.000 a R$ 15.000 em produtos simples ou lançamentos incorretos).

6. Identificação e Remoção de Duplicatas

- **Deduplicação:** O código identificou linhas completamente duplicadas na base e aplicou o método drop_duplicates(keep='first') para reter apenas a primeira ocorrência, eliminando as repetições excedentes.

7. Auditoria Cruzada com o Gabarito

- **Validação Final:** O script realizou uma auditoria cruzada utilizando a aba de gabarito de erros (gabarito_erros) embutida na planilha original.
- **Resumo das Anomalias:** Foram catalogadas e categorizadas **228 anomalias** na base original, divididas entre erros em clientes, valores unitários, duplicidades, datas, produtos e quantidades.
- **Resultado:** O pipeline de limpeza concluiu com sucesso o tratamento de todas as falhas mapeadas, entregando uma base refinada e consistente com **485 registros válidos** (uma redução controlada a partir dos 547 iniciais).